

AVALIAÇÃO – DATA SCIENCE MANAGER




Leandro Carvalho

Conteúdo restrito e confidencial para avaliação. Sem uso comercial.

AGENDA

Agenda



➤ Questão 01

➤ Questão 02


➤ Questão 03

➤ Questão 04

QUESTÃO 01



- Importação dos arquivos JSON para tabelas em um banco de dados
- Transformação
- Estatísticas básicas com Python
- Processo de Decisão: definição dos Ranges
- Frequência e a probabilidade de ocorrência
- Resultados
- Conclusões
- Ações estratégicas e Insights



Transformação



SELECT

```
StudentID, RegisteredDate, SubscriptionDate,  
DATEDIFF(HOUR, RegisteredDate, SubscriptionDate) as Horas,  
DATEDIFF(HOUR, RegisteredDate, SubscriptionDate)/24 as Dias,  
((DATEDIFF(HOUR, RegisteredDate, SubscriptionDate)/24)/7) as Semanas,  
FLOOR((DATEDIFF(HOUR, RegisteredDate,  
SubscriptionDate)/24)/30.436875E) as Meses
```

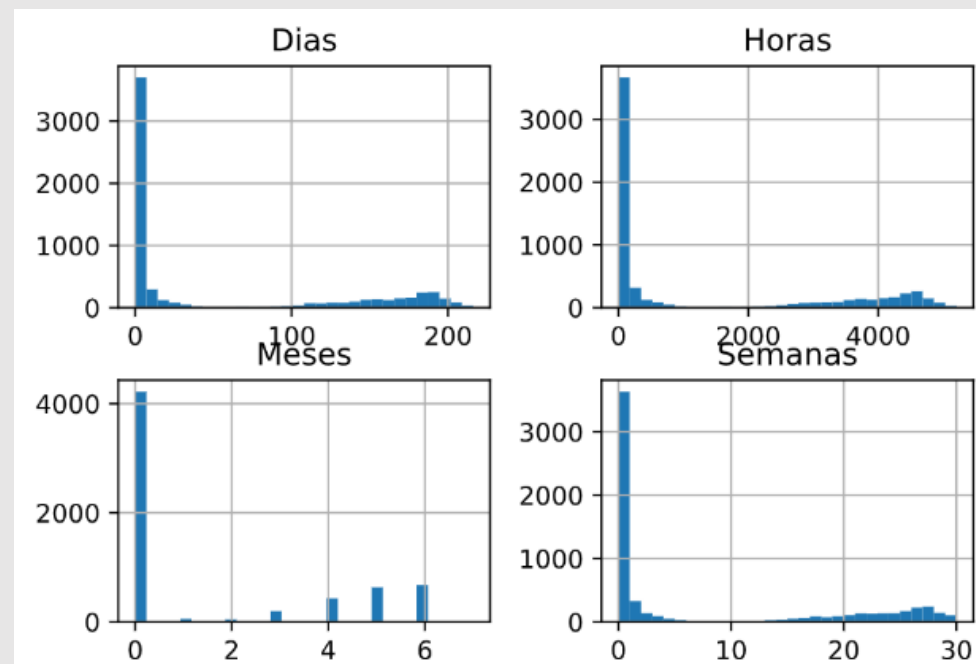
FROM

```
[PD_A-01-premium_students]
```

ORDER BY


```
DATEDIFF(HOUR, RegisteredDate, SubscriptionDate)
```

| | count | mean | std | min | 25% | 50% | 75% | max |
|---------|--------|-------------|-------------|-----|-----|------|--------|--------|
| Horas | 6260.0 | 1293.789457 | 1843.913431 | 0.0 | 2.0 | 39.0 | 3290.0 | 5205.0 |
| Dias | 6260.0 | 53.627636 | 76.729395 | 0.0 | 0.0 | 1.0 | 137.0 | 216.0 |
| Semanas | 6260.0 | 7.446965 | 10.817838 | 0.0 | 0.0 | 0.0 | 19.0 | 30.0 |
| Meses | 6260.0 | 1.552077 | 2.339325 | 0.0 | 0.0 | 0.0 | 4.0 | 7.0 |




Definição dos Ranges

| Período | Descrição – Motivos |
|------------------|---|
| 24 horas | Usuários que se tornaram Premium dentro do período de até 24 horas. |
| 1 dia | Usuários que, após as 24 horas iniciais, se tornaram Premium no dia seguinte. |
| 2 dias | Usuários que se tornaram Premium no 2º dia após o cadastro. |
| até 7 dias | Usuários que, após o segundo dia, se tornaram Premium em até 1 semana. |
| até 15 dias | Usuários que se tornaram Premium em até 15 dias após o cadastro. |
| até 30 dias | Usuários que, após a 1ª quinzena, se tornaram Premium em até 30 dias após o cadastro. |
| No mês seguinte | Usuário que após o 1º mês de uso no modelo free, se tornaram Premium no mês seguinte (até 60 dias). |
| 2 meses | Usuários que experimentaram por mais de 60 dias (o equivalente a um bimestre escolar) e se tornaram Premium no bimestre seguinte. |
| 3-4 meses | Usuários que se tornaram Premium após o fim do primeiro bimestre. |
| 5-6 meses | Usuários que levaram até 6 meses para se tornarem Premium. |
| acima de 6 meses | Usuários que se tornaram Premium após 6 meses. |




“Definição de Range depende da regra de negócio” – Leandro Carvalho

Probabilidade



| Período | Assinantes | Probabilidade |
|------------------|------------|---------------|
| 24 horas | 2988 | 47,73% |
| 1º dia | 202 | 3,23% |
| 2º dias | 121 | 1,93% |
| até 7 dias | 388 | 6,20% |
| até 15 dias | 296 | 4,73% |
| até 30 dias | 223 | 3,56% |
| No mês seguinte | 57 | 0,91% |
| 2 meses | 44 | 0,70% |
| 3-4 meses | 626 | 10,00% |
| 5-6 meses | 1309 | 20,91% |
| acima de 6 meses | 6 | 0,10% |



- Importação dos arquivos JSON para tabelas em um banco de dados
- Transformação
- Estatísticas básicas com Python.
- Processo de Decisão: definição dos Ranges
- Frequência e a probabilidade de ocorrência.
- Resultados
- Conclusões
- Ações estratégicas e Insights




- Há uma **probabilidade** muito **maior de conversão** (47,73%) dentro do período de **24 horas**;
- Nos dias seguintes, a **taxa cai** bastante: **3,23%** no **primeiro dia** e **1,93%** no **segundo**;
- Não convertendo em de 3 dias, a chance de **conversão** em até **1 semana** é de **6,20%** e em **15 dias** é de **4,73%**);
- Nota-se que **há um aumento de 10%** na conversão a partir da **faixa entre 3 – 4 meses**. Vale ressaltar que esta faixa representa o bimestre seguinte a partir da data do cadastro.;
- O mesmo ocorre na faixa entre **5-6 meses**, com **aumento de 20,91%**;
- A partir dos **6 meses**, é **remota a probabilidade de conversão** (lembrando que o valor máximo em meses é igual a 7 e que são poucos os registros que chegam até este valor, ou seja, há um desbalanceamento na nesta última classe em relação com as demais).

- Tendo em vista que **as chances de conversão** se concentram **dentro** do período de **até 2 dias**, com um total **de 52,89%** (levando em consideração **as 3 primeiras faixas do range**) a empresa precisa agrupar os esforços de marketing neste período:
- Garantir a **excelência** e um **suporte ativo** no **atendimento** aos clientes já no **1º contato**;
- Avaliar a **criação de um modelo preditivo** (a partir dos **dados de engajamento**, padrão de **consumo e comportamento**) para inferir **se um usuário** poderá ou não se tornar **ativo em até 2 dias** (ou a criação de vários modelos para cada faixa);
- Para os **usuários** indicados como alta **probabilidade de não se tornarem ativos** dentro do prazo de **até 2 dias** (ou até mesmo em 24 horas, por que não), **criar uma comunicação ativa**, com uma abordagem suave e **sem incomodar**, para que o time de comercial de ativação consiga **converter o usuário**;



Ações e Insights

- Para **reforçar a sugestão** sobre a criação do modelo preditivo, gerei um **novo histograma** com os dados dos **usuários ativos (premium)** dentro das primeiras **24 horas**
- Nele, é possível observar que as **4 primeiras horas** são **fundamentais na decisão** do usuário de **assinar** ou não o serviço.
- A partir daí o **interesse** do usuário **cai conforme as horas vão passando**.
- Por isso, vale a pena experimentar a **criação de um modelo**, mas desde que sejam **criadas ações estratégicas** efetivas para dar **suporte ao time de Growth, Marketing e Vendas**;





- É preciso **observar** de perto o **resultado do modelo**, para **não só avaliar a conversão** dentro do período, mas também se haverá uma não conversão maior ao longo do tempo;
- Pois **se a ação ativa do time de Growth não for bem-sucedida**, o usuário poderá **bloquear os contatos** da empresa e até mesmo se tornar um detrator.
 - Ex.: Se entrar em contato com uma pessoa que já iria assinar, ela pode ficar chateada e desistir.


Ações e Insights

➤ Acompanhar a conversão de forma gráfica

| | 2017-11 | 2017-12 | 2018-01 | 2018-02 | 2018-03 | 2018-04 | 2018-05 | 2018-06 |
|------------|---------|---------|---------|---------|---------|---------|---------|---------|
| 2017-11-01 | 2,19% | 0,00% | 0,00% | 0,02% | 0,08% | 0,29% | 0,43% | 0,03% |
| 2017-11-02 | 2,48% | 0,02% | 0,00% | 0,03% | 0,11% | 0,38% | 0,56% | 0,03% |
| 2017-11-03 | 2,22% | 0,08% | 0,02% | 0,03% | 0,08% | 0,21% | 0,40% | 0,03% |
| 2017-11-04 | 2,43% | 0,02% | 0,02% | 0,03% | 0,06% | 0,29% | 0,54% | 0,08% |
| 2017-11-05 | 3,96% | 0,08% | 0,00% | 0,02% | 0,19% | 0,22% | 0,86% | 0,10% |
| 2017-11-06 | 3,29% | 0,14% | 0,02% | 0,00% | 0,14% | 0,45% | 0,77% | 0,08% |
| 2017-11-07 | 2,54% | 0,05% | 0,02% | 0,08% | 0,26% | 0,48% | 0,67% | 0,05% |
| 2017-11-08 | 2,81% | 0,24% | 0,00% | 0,08% | 0,14% | 0,26% | 0,46% | 0,08% |
| 2017-11-09 | 2,22% | 0,10% | 0,02% | 0,00% | 0,10% | 0,37% | 0,53% | 0,10% |
| 2017-11-10 | 2,17% | 0,13% | 0,03% | 0,02% | 0,14% | 0,26% | 0,38% | 0,08% |
| 2017-11-11 | 2,09% | 0,11% | 0,02% | 0,06% | 0,11% | 0,22% | 0,45% | 0,06% |
| 2017-11-12 | 2,68% | 0,08% | 0,00% | 0,08% | 0,08% | 0,35% | 0,54% | 0,06% |
| 2017-11-13 | 4,31% | 0,18% | 0,03% | 0,03% | 0,19% | 0,58% | 1,13% | 0,11% |
| 2017-11-14 | 4,90% | 0,14% | 0,00% | 0,05% | 0,26% | 0,58% | 1,15% | 0,14% |
| 2017-11-15 | 2,81% | 0,05% | 0,03% | 0,02% | 0,14% | 0,50% | 0,38% | 0,08% |
| 2017-11-16 | 2,80% | 0,26% | 0,02% | 0,02% | 0,26% | 0,43% | 0,48% | 0,13% |
| 2017-11-17 | 1,84% | 0,14% | 0,02% | 0,00% | 0,14% | 0,42% | 0,61% | 0,03% |
| 2017-11-18 | 1,85% | 0,14% | 0,00% | 0,06% | 0,16% | 0,16% | 0,40% | 0,08% |
| 2017-11-19 | 3,04% | 0,21% | 0,00% | 0,00% | 0,18% | 0,26% | 0,54% | 0,05% |
| 2017-11-20 | 2,36% | 0,34% | 0,00% | 0,11% | 0,37% | 0,35% | 0,51% | 0,06% |
| 2017-11-21 | 1,34% | 0,19% | 0,00% | 0,06% | 0,24% | 0,48% | 0,48% | 0,10% |
| 2017-11-22 | 1,01% | 0,19% | 0,00% | 0,05% | 0,13% | 0,30% | 0,42% | 0,11% |
| 2017-11-23 | 0,85% | 0,14% | 0,00% | 0,10% | 0,08% | 0,27% | 0,35% | 0,06% |
| 2017-11-24 | 0,85% | 0,06% | 0,00% | 0,03% | 0,19% | 0,14% | 0,24% | 0,05% |
| 2017-11-25 | 0,53% | 0,08% | 0,00% | 0,03% | 0,14% | 0,16% | 0,19% | 0,00% |
| 2017-11-26 | 0,75% | 0,21% | 0,02% | 0,02% | 0,10% | 0,16% | 0,11% | 0,02% |
| 2017-11-27 | 1,28% | 0,26% | 0,00% | 0,02% | 0,22% | 0,24% | 0,18% | 0,03% |
| 2017-11-28 | 0,83% | 0,24% | 0,06% | 0,05% | 0,19% | 0,19% | 0,16% | 0,10% |
| 2017-11-29 | 0,75% | 0,24% | 0,00% | 0,03% | 0,14% | 0,29% | 0,16% | 0,05% |
| 2017-11-30 | 0,58% | 0,35% | 0,00% | 0,00% | 0,03% | 0,19% | 0,14% | 0,03% |



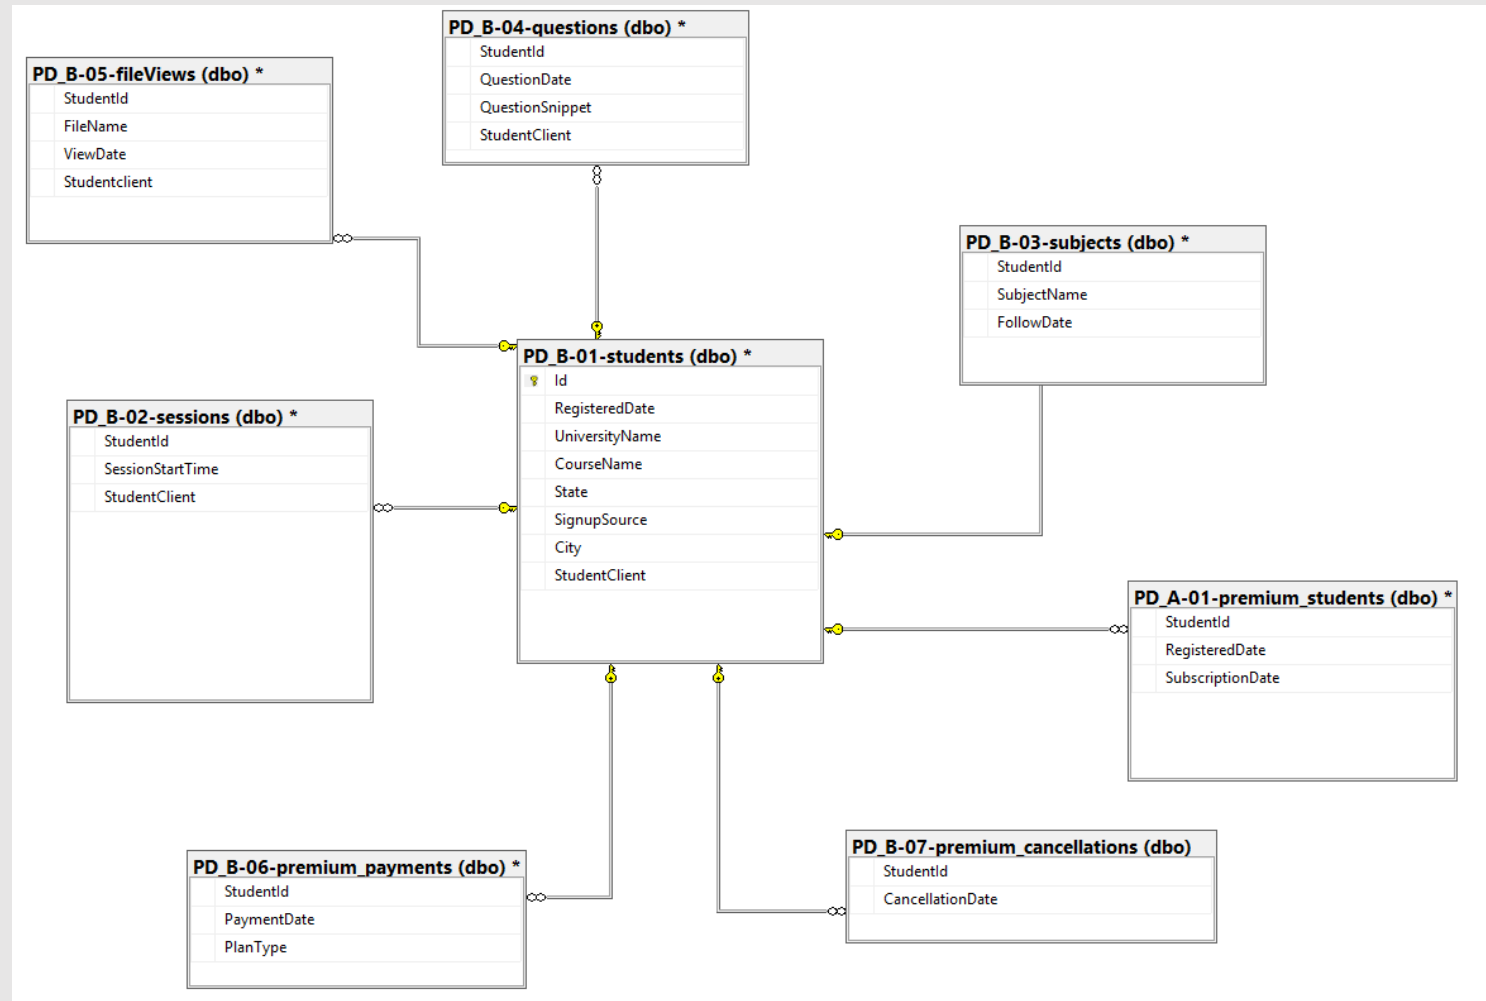
- Tendo em vista que **as chances de conversão** se concentram **dentro** do período de **até 2 dias**, com um total **de 52,89%** (levando em consideração **as 3 primeiras faixas do range**) a empresa precisa agrupar os esforços de marketing neste período,





QUESTÃO 02



- Estruturação das tabelas no Banco de Dados;
- Exploração dos dados para ver os pagamentos e as assinaturas durante o período
- LTV
 - Mensal
 - Anual
 - Cliente Novo
 - Cliente Recorrente
 - LTV Final




Exploração dos dados



- Nota-se sem dúvida que houve um **crescimento** nos pagamentos **a partir** de **novembro de 2017**;
- **Decisão acertada** em termos de estratégia de negócio (parte financeira).
- **Obs.:** É preciso ter em mente que **há clientes com mais de um pagamento no período**. Neste caso, por uma questão de **análise**, foi feito um **DISTINCT** na base de dados para **contar** somente **1 pagamento por cliente** em cada período (por plano).

- Há **várias formas** para se calcular o **LTV**, a maioria utiliza a taxa de CHURN. Porém, há também **várias formas** de se calcular o **CHURN**. Ex.:
 - Clientes do **mês anterior** que **não assinaram** o mês **atual**;
 - Clientes que se **cadastram** no mês atual e **cancelaram no próprio mês**; ou
 - Um **somatório dos 2** para se tirar uma média.



LTV - Mensal

- Identificação dos usuários ativos no plano mensal;
- Em outubro houve pagamento de 286 clientes distintos (apesar de termos 288 registros de pagamentos no período – 1 usuário com 2 pagamentos). Destes clientes, 13 cancelaram em outubro;
- Assim, um total de 273 clientes assinantes começaram o mês de novembro. Porém, destes clientes, 29 cancelaram em novembro (Levei em consideração apenas os clientes que pediram formalmente o cancelamento. Não levei em consideração os clientes que deixaram de pagar, até porque o time comercial poderia estar negociando a permanência deles).
- Em nov. /2017 718 clientes novos se cadastraram no plano anual. Destes clientes, 67 cancelaram no mesmo mês.
 - CHURN Plano Mensal
 - Clientes Recorrente = $29 / 273 = 10,62\%$
 - Novos Clientes = $67 / 718 = 9,33\%$
 - LTV Plano Mensal (levarei em consideração a fórmula padrão $LTV = ARPA/Churn$)
 - Clientes Recorrente = $R\$ 29,90 / 10,62\% = R\$ 281,54$
 - Novos Clientes = $R\$ 29,90 / 9,33\% = R\$ 320,47$



LTV - Anual

- Identificação dos usuários ativos no plano **anual**;
- Em **out./2017** havia **101 clientes ativos** no plano **anual**.
- Destes, **57 novos clientes** se cadastram em **nov. /2017** o plano **anual**. Destes clientes, **nenhum cancelou no próprio mês** de cadastro;
- **3 clientes recorrentes** (dos 101 que começaram o mês como ativos) **cancelaram** o plano anual em **nov.2017**;
- **3 clientes** deveriam ter renovado o plano em nov./2017 mas **não o fizeram**.
- Ao final, a **base de assinantes** premium do plano **anual** ficou com um **total de 152 clientes distintos ativos** em **nov./2017**;
- **CHURN Plano Anual**
 - Clientes Recorrente = $6 / 101 = 5,94\%$
 - Novos Clientes = $0 / 57 = 0\%$ (sem churn)
- **LTV Plano Anual** (levarei em consideração a fórmula padrão $LTV = ARPA/Churn$)
 - Clientes Recorrente = $R\$ 23,90 / 10,62\% = R\$ 402,32$
 - Novos Clientes = Como a taxa de churn destes clientes ficou igual a zero **não foi possível calcular** o LTV, mas **existem algumas fórmulas** para isso.



LTV – Tipo de Cliente

➤ CHURN POR TIPO DE CLIENTE

➤ Clientes **Recorrente** = $(29 + 6) / (273 + 101) = 9.36\%$

➤ **Novos** Clientes = $(67 + 0) / (718 + 57) = 8,65\%$

➤ LTV POR TIPO DE CLIENTE

➤ Clientes **Recorrente** = $R\$ 29,90 / 9.36\% = R\$ 319,44$

➤ **Novos** Clientes = $R\$ 23,90 / 8,65\% = R\$ 276,30$



➤ **CHURN FINAL TOTAL** = $102 / 1.149 = 8,88\%$

(utilizando os padrões encontrados por tipo de cliente e tipo de assinatura).

➤ **ARPA (Nov./2017)** = $(152 \text{ clientes anuais} \times \text{R\$ } 23,90) + (895 \text{ clientes mensais} \times \text{R\$ } 29,90)$
 $= (3.632,80 + 26.760,50) = 30.393,30 / 1.047 = \text{R\$ } 29,03$

➤ **LTV TOTAL** = $29,03 / 8,88\% = \text{R\$ } 326,91$



QUESTÃO 03

- Criar uma **análise** para **entender** o **motivo** pelo qual um cliente **assina e logo cancela** o plano mensal.
 - Será que ele chegou a **consumir algo e não gostou**?
 - Ou **consumiu** o que queria a tempo de cancelar o seu cadastro dentro do primeiro mês (**baixou tudo**) e **foi embora**?
 - Seria importante **ir em busca de um padrão**, até para **garantir** o fornecimento de uma **melhor experiência aos usuários futuros**;



- Gerar um **modelo de regressão** que permita **inferir a QUANTIDADE de usuários que irão cancelar** a assinatura do serviço (se tornarão **Churn**) em um determinado período futuro.
- Isto **permitirá** a empresa fazer um **melhor planejamento** de dimensionamento da equipe, dos recursos computacionais e financeiros;



- Criar um *modelo de Machine Learning* para prever **QUEM SÃO OS** são os clientes que irão cancelar;
- Isto poderia ser feito a partir dos dados de *consumo*, *engajamento* e *histórico* dos cancelamentos;
- Com este modelo, a equipe de Grow, sustentação e marketing poderiam *desenvolver ações para tentar mitigar as perdas*;



- Desenvolvimento de um Chatbot que permita ao usuário interagir com o conteúdo cadastrado na plataforma a partir de uma curadoria feita por IA.
 - Neste caso, seria possível entregar um conteúdo mais assertivo, a partir dos seus desejos e padrões de engajamento e consumo, além de economizar o tempo de pesquisa do usuário.
 - Assim, ele o aluno teria mais tempo para o que importa, ou seja, estudar a matéria e não em ter que ficar procurando o conteúdo mais apropriado.



- Conforme já informado, a criação de um **modelo preditivo** para **sugerir se um usuário** poderá **se tornar ativo** ou não assim que fizer o cadastro.
 - Uma vez criado o modelo, é preciso ter **ações estratégicas bem definidas** (time comercial e marketing) sobre o que fazer.
 - Será que **vale a pena entrar em contato** com o cliente? Se sim, **de que maneira?** Email ou telefone/WhatsApp?
 - E com qual **periodicidade?**
 - É bom ter em mente que estas **respostas só** aparecerão com o **uso do modelo**, **monitorando** dos seus **resultados** e com o **tempo**;



- Criação de modelos de *Machine Learning* (classificação não supervisionada) que permitam identificar os diversos perfis de clientes a partir dos dados de engajamento, padrão de consumo e comportamento e comportamento.
- A partir deste modelo, prever o comportamento futuro para melhorar a experiência dos usuários e garantir para a empresa que os números de crescimento, engajamento e receitas estejam sempre aumentando.



- Gerar um modelo de **text-mining** para **segmentar** os **termos de buscas** feitos na plataforma e as **perguntas** feitas pelos usuários (registrados na tabela questions) para **determinar o melhor conteúdo** e a **área de domínio** do assunto pesquisado.
 - A ideia seria **otimizar** a entrega com um conteúdo de mais relevante para o usuário.



QUESTÃO 04




- Escolha da Segmentação – Processo
- Segmentação Comportamental
- Segmentação com *Machine Learning*

Escolha da Segmentação



- A base permite uma **segmentação** sócio demográfica, mas optei por uma **análise comportamental**, utilizando o **modelo RFM**.
 - A ideia é **buscar** um **padrão de consumo** dos usuários *premium*.
 - Assim, farei uma segmentação que **atenda** as diversas **áreas** do PD (**Marketing, Vendas, Growth, Retenção e Financeiro**);
 - Seguindo o modelo RFM, vou considerar uma análise **temporal** dos clientes, utilizando as **informações** sobre o quão **recente** é um cliente (**último engajamento**);
 - Em conjunto com uma análise **financeira**, ou seja, o **quanto** que um cliente **gastou**;
 - E por último, uma **análise de fidelidade** com base nos dados de **engajamento** do cliente por **sessões iniciadas** (até poderia qualificar o engajamento por questões postadas no site ou por visualizações de arquivos. Porém, farei somente por sessão, manterei de forma mais simples a análise);



- A primeira etapa necessária foi **definir um período para análise**.
 - Neste caso, defini um **intervalo** de tempo entre **nov./2017** até **mai./2018**;
 - **Motivo: analisar o histórico comportamental** dos usuários nos **6 meses** seguintes após a **mudança** informada na questão 3 (**Content Restriction**);
- Na sequência, fui até a base e **agrupei os dados** necessários para a análise. Em seguida, **exportei** para um arquivo .csv e **criei 2 modelos** utilizando linguagem **Python**.
 - O **primeiro**, seguiu o modelo **RFM tradicional** (divisão dos valores dos clientes em percentis);
 - O **segundo**, foi feito utilizando **Machine Learning**, através de um algoritmo de classificação não supervisionada, mas seguindo a mesma ideia do modelo RFM.

| | DiasSemUso | TotalSessoes | TotalGasto | Qtd. Clientes |
|-----------|------------|--------------|------------|---------------|
| RFM_Level | | | | |
| Green | 16.8 | 30.4 | 38.8 | 499 |
| Bronze | 37.8 | 38.5 | 86.1 | 692 |
| Silver | 48.0 | 54.2 | 149.5 | 299 |
| Gold | 42.9 | 73.9 | 164.3 | 200 |

- Neste cenário o conjunto de dados foi dividido em 4 grupos, sendo: Green, Bronze, Silver e Gold.
 - Gold são os clientes VIPs, possuem o maior gasto médio durante todo o período, possuem o maior engajamento;
 - Silver também possui um gasto elevado, porém com um engajamento menor que o Gold e com um tempo de inatividade um pouco maior;
 - Bronze possui um tipo de cliente que gasta quase a metade do que gasta os clientes dos grupos Silver e Gold e possuem um engajamento também menor;
 - Green, pelo que parece, representa os novos clientes, aqueles mais recentes, não só pela média do último dia de acesso, como também pelo seu gasto médio (lembrando, os valores refletem a média de gastos no período, que é impactado pelo tempo como assinante premium).




- Com estes resultados o **marketing** poderia, por exemplo, **customizar as mensagens** de acordo com o **perfil temporal** do cliente (aquele está a mais tempo sem se conectar na plataforma).
 - Ex.: Fazer uma **campanha** para os **usuários do grupo Green** com estratégias relacionadas ao **pós-venda**;
 - Já para o grupo do **Silver**, que está **há 48 dias sem acesso**, **informar** sobre os **novos conteúdos** inseridos na plataforma, e que sejam **relacionados** aos seus **interesses**.
- Pelo lado **financeiro**, as equipes de **retenção e/ou ativação**, poderiam **acompanhar** de perto os usuários do grupo **Gold**, pois embora sejam aqueles que mais gastam, eles **já estão há 42 dias (em média) sem acessar a plataforma**. Estes usuários **não podem ser perdidos**.

| | DiasSemUso | TotalSessoes | TotalGasto | |
|-----------|------------|--------------|------------|-------|
| | mean | mean | mean | count |
| K_Cluster | | | | |
| 0 | 7.28 | 139.88 | 200.33 | 64 |
| 1 | 11.47 | 30.55 | 38.53 | 709 |
| 2 | 12.76 | 32.80 | 205.42 | 271 |
| 3 | 157.74 | 18.76 | 50.98 | 175 |
| 4 | 19.63 | 32.56 | 114.23 | 293 |
| 5 | 10.30 | 512.90 | 66.97 | 10 |
| 6 | 6.96 | 138.26 | 54.16 | 105 |
| 7 | 177.68 | 12.67 | 190.32 | 63 |

- Na busca por um resultado mais detalhado, utilizei o modelo RFM com Machine Learning. Os dados foram divididos em 8 clusters (melhor K partir da análise do método Elbow)

- Ao que parece o **cluster 1** representa os clientes **mais novos** em relação às assinaturas realizadas, pois o **valor médio é de 38,53** (muito próximo do valor mensal das assinaturas premium);
- Os **cluster 3 e 7** poderiam representar os **clientes perdidos**, pois **estão a mais tempo** sem se **conectar a plataforma** (um bom grupo para o time de **ativação** do Passei Direto);
- O **cluster 0** pode ser considerado **VIP**, já que possui os clientes um **bom gasto** ao longo do período, são **muito ativos** e **usaram recentemente** a plataforma;
- O **cluster 2** é também um **bom cluster**, pois possui a **maior média de gatos**, além de ser **recente**. A única diferença é que o **engajamento** médio na plataforma **é menor**;



Obrigado – FIM

